

SOLICITUD PARA LA AUTORIZACIÓN DEL TFG

Don/Doña Nadia González Guarner, con D.N.I. nº 51494298N y domicilio en la Calle Don Quijote nº 22 C.P.28430 de Alpedrete provincia de Madrid.

EXPONE:

Que estando matriculado de todas las asignaturas que restan para la obtención del título Business Analytics.

Confirmando haber aprobado todas las asignaturas correspondientes al grado de Business Analytics y las asignaturas necesarias para su reconocimiento.

y deseando realizar el Trabajo Final de Grado con el título “Comparativa del índice sentimiento del consumidor con el análisis de sentimiento del discurso con tweets de ministerio de comercio en distintos momentos”

SOLICITA:

Se autorice la petición formulada.

Fdo.: _____

Madrid, a ____ de _____ de 20__



ANTEPROYECTO

COMPARATIVA DEL ÍNDICE SENTIMIENTO DEL CONSUMIDOR CON EL ANÁLISIS DE SENTIMIENTO DEL DISCURSO CON TWEETS DE MINISTERIO DE COMERCIO EN DISTINTOS MOMENTOS

COMPARISON OF THE CONSUMER SENTIMENT INDEX WITH DISCOURSE
SENTIMENT ANALYSIS OF TWEETS FROM THE MINISTRY OF TRADE AT DIFFERENT
TIMES

Alumno: Nadia González Guarner

Email: nadia122004@gmail.com

Grado en Business Analytics

Curso académico 2025-2026

ÍNDICE

1.	DESCRIPCIÓN DEL PROBLEMA A RESOLVER.....	1
1.1.	Motivación y origen	1
1.2.	Datos que lo sustentan	2
1.3.	Impacto de la solución del problema	3
1.4.	Problema de investigación en forma de pregunta	3
1.5.	Preguntas de investigación	4
1.6.	Planificación del proyecto.....	4
1.7.	Estado del arte	6
2.	OBJETIVO GENERAL Y OBJETIVOS ESPECÍFICOS	10
2.1.	Objetivo general	10
2.2.	Objetivos específicos	10
3.	METODOLOGÍA.....	11
3.1.	Fuentes de datos.....	11
3.2.	Procedimiento metodológico	12
4.	REFERENCIAS	13

Índice de tablas

Tabla 1 Cronograma del proyecto.....	6
Tabla 2 Fuentes de datos utilizadas	12

1. DESCRIPCIÓN DEL PROBLEMA A RESOLVER

1.1. Motivación y origen

El punto de partida del trabajo es concreto: el Índice de Confianza del Consumidor permite observar cómo perciben los hogares la situación económica, pero no muestra cómo se comunica institucionalmente ese mismo contexto. El ICC mide percepción ciudadana. El discurso publicado por una institución pública en X/Twitter mide otra cosa: la señal comunicativa que la institución decide emitir. Esta diferencia es central para el proyecto.

A efectos metodológicos, el concepto de índice sentimiento del consumidor se operacionaliza mediante el Índice de Confianza del Consumidor, elaborado por el Centro de Investigaciones Sociológicas. Esta decisión permite trabajar con una serie oficial, mensual, comparable en el tiempo y vinculada a la percepción económica de los hogares. El trabajo no construye un índice alternativo de opinión ciudadana. Utiliza el ICC como variable oficial de referencia.

La segunda dimensión del proyecto es el tono del discurso institucional en X/Twitter. Las cuentas públicas vinculadas al ámbito económico-comercial comunican medidas, campañas, datos, convocatorias y mensajes dirigidos a empresas, consumidores y ciudadanía. Ese discurso no equivale a la opinión pública. Es una señal emitida desde la institución. Precisamente por eso resulta interesante compararlo con el ICC: permite analizar si el tono institucional acompaña, se distancia o presenta desfases respecto al clima económico percibido por los hogares.

El periodo 2020-2025 ofrece un contexto especialmente útil para esta comparación. Incluye la pandemia de COVID-19, la recuperación posterior, la subida de precios, la crisis energética y una fase de estabilización económica parcial. En un intervalo tan heterogéneo, mantener un tono institucional estable puede tener una interpretación distinta a ajustarlo de forma visible a los cambios del entorno.

La comparación no busca demostrar causalidad. El trabajo no afirma que los tweets modifiquen el ICC ni que el ICC determine automáticamente el tono de los tweets. La pregunta es más acotada y defendible: si ambas series presentan patrones de alineación, desfase o divergencia cuando se observan con la misma unidad temporal, el mes.

1.2. Datos que lo sustentan

El problema de investigación se sustenta en dos fuentes de datos complementarias: una serie oficial mensual, el ICC, y una base de publicaciones institucionales obtenidas de X/Twitter mediante técnicas de web scraping. La combinación de ambas fuentes permite pasar de textos no estructurados a una comparación temporal reproducible.

La serie histórica del ICC está disponible desde septiembre de 2004 hasta enero de 2026. Para el presente trabajo se selecciona el periodo enero 2020-diciembre 2025. Este periodo contiene 72 meses posibles. De ellos, 68 disponen de dato de ICC comparable. Los meses ausentes corresponden a agosto de 2022, agosto de 2023, agosto de 2024 y agosto de 2025, debido a la ausencia de publicación del indicador en esos meses estivales. Esta ausencia no se imputa; se documenta y se excluye de las comparaciones que requieren dato oficial.

Como referencia inicial, el ICC se situaba en 87,2 puntos en enero de 2020 y descendió a 49,9 puntos en abril de 2020. Esta caída ilustra la sensibilidad del indicador ante episodios económicos y sociales extremos. El periodo posterior permite observar fases de recuperación, nuevas tensiones asociadas a precios y energía, y ajustes posteriores en las expectativas de los hogares.

La base de tweets procede de publicaciones públicas en X/Twitter, obtenidas mediante scraping web ante las limitaciones de acceso gratuito a la API oficial de la plataforma. La base inicial contiene 11.198 registros publicados entre 2012 y 2026. Cada registro incluye identificador del tweet, fecha, usuario emisor, texto, hashtags, tipo de publicación, enlace a contenido multimedia y métricas públicas de interacción, como comentarios, retweets, likes y visualizaciones.

Para el análisis principal se trabaja con el periodo 2020-2025. La cuenta @_minecogob se utiliza como corpus principal porque ofrece mayor volumen, cobertura temporal completa y mejor comparabilidad mensual con el ICC. Tras el filtrado, limpieza y deduplicación, el corpus principal final utilizado en el análisis queda compuesto por 4.590 tweets. La cuenta @SE_Comercio se conserva como fuente complementaria, útil para contextualizar el ámbito comercial, pero con menor volumen para construir una serie mensual robusta.

Esta diferencia entre corpus inicial y corpus final es metodológicamente importante. Los 11.198 registros describen la base bruta disponible. Los 4.590 tweets

describen el corpus principal limpio y comparable usado en el análisis final. No son cifras contradictorias, sino fases distintas del proceso de ingeniería del dato.

1.3. Impacto de la solución del problema

El impacto del proyecto se entiende en tres planos: académico, metodológico y aplicado.

En el plano académico, el trabajo se sitúa en la intersección entre confianza del consumidor, comunicación institucional y análisis de sentimiento. La literatura ha estudiado ampliamente el ICC, el sentimiento económico en fuentes digitales y la comunicación institucional en redes sociales. Sin embargo, son menos frecuentes los trabajos que comparan directamente un indicador económico oficial con el tono del discurso institucional emitido por una cuenta pública del ámbito económico-comercial.

En el plano metodológico, el proyecto transforma texto institucional no estructurado en una serie mensual de tono. El análisis de sentimiento se aplica tweet a tweet y las etiquetas se agregan después por mes para construir el Índice de Tono Institucional mensual, ITIm. Esta decisión evita comparar observaciones individuales con una serie mensual. El análisis se realiza a nivel mensual porque el ICC es una serie mensual.

En el plano aplicado, el resultado puede servir como herramienta de seguimiento comunicativo. Si el ITIm y el ICC muestran alineación, el análisis permite identificar en qué periodos el tono institucional acompaña el clima económico percibido. Si divergen, el resultado también es útil, porque señala meses que requieren revisión cualitativa. La ausencia de relación no sería un fracaso del trabajo; sería una evidencia de que ambas señales evolucionan de forma relativamente independiente o responden a factores distintos.

El valor del proyecto no está en predecir el ICC. Está en hacer observable una dimensión que normalmente queda dispersa en cientos o miles de publicaciones: el tono mensual del discurso institucional.

1.4. Problema de investigación en forma de pregunta

El problema de investigación se formula mediante la siguiente pregunta principal:

¿Existe relación temporal entre la evolución mensual del Índice de Confianza del Consumidor y el tono del discurso institucional publicado en X/Twitter por cuentas del ámbito económico-comercial durante el periodo 2020-2025?

La pregunta delimita el alcance del trabajo. Se analiza relación temporal, no causalidad. Se compara una variable de percepción ciudadana agregada con una variable de comunicación institucional. El objetivo es observar patrones de alineación, desfase o divergencia entre ambas series.

1.5. Preguntas de investigación

1. ¿Cómo evoluciona mensualmente el Índice de Confianza del Consumidor durante el periodo 2020-2025?
2. ¿Qué tono predomina en los tweets institucionales analizados: positivo, negativo o neutro?
3. ¿Cómo evoluciona mensualmente el tono institucional construido a partir del corpus de tweets?
4. ¿Qué grupos temáticos recurrentes pueden identificarse en el corpus de tweets institucionales mediante técnicas no supervisadas de text mining?
5. ¿Existe asociación estadística entre el ITIm y la evolución mensual del ICC?
6. ¿Se observan desfases temporales entre ambas variables cuando se comparan el mes anterior, el mes contemporáneo y el mes posterior?
7. ¿Qué meses muestran divergencias destacadas entre el tono institucional y el ICC?
8. ¿Qué limitaciones presenta el análisis automático de sentimiento cuando se aplica a comunicación institucional, caracterizada por un lenguaje formal, técnico y frecuentemente neutro?
9. ¿Qué utilidad puede tener el ITIm como herramienta de seguimiento comunicativo sin convertirlo en predictor del ICC?

1.6. Planificación del proyecto

La planificación del proyecto se estructura de acuerdo con la secuencia metodológica del análisis. En primer lugar, se delimita el problema de investigación y se revisa la literatura sobre confianza del consumidor, comunicación institucional y análisis de sentimiento. A continuación, se preparan las fuentes de datos, formadas por la serie mensual del ICC y el corpus de tweets institucionales, aplicando los procesos necesarios de filtrado, limpieza y normalización.

Una vez construido el corpus final, se aplican dos modelos de text mining con funciones diferenciadas. El primero es un modelo preentrenado de análisis de sentimiento, utilizado para clasificar cada tweet como positivo, negativo o neutro y construir posteriormente el Índice de Tono Institucional mensual (ITIm). El segundo es un modelo no supervisado de agrupación temática, basado en la similitud textual entre tweets, que permite identificar bloques de contenido recurrentes dentro del discurso institucional. La última fase del proyecto consiste en comparar el ITIm con el ICC mediante visualizaciones, correlaciones, desfases temporales y variaciones intermensuales, con el objetivo de identificar patrones de alineación, desfase o divergencia sin establecer conclusiones causales.

1.6.1 Cronograma

Fase	Periodo previsto	Actividades	Entregable
1. Definición del problema y anteproyecto	Abril, semana 1	Revisión del tema, delimitación de la pregunta principal, ajuste del enfoque y alineación con la plantilla.	Problema de investigación y estructura del anteproyecto.
2. Revisión bibliográfica y estado del arte	Abril, semanas 2-3	Revisión de literatura sobre ICC, sentimiento económico, comunicación institucional, PLN y modelos en español.	Estado del arte preliminar y referencias seleccionadas.
3. Cierre del anteproyecto	Abril, semana 4	Redacción de motivación, datos, impacto, preguntas, planificación, objetivos y metodología.	Anteproyecto corregido y listo para entrega.

4. Ingeniería del dato	Mayo, semanas 1-2	Preparación de fuentes, limpieza de tweets, normalización de fechas, tratamiento de duplicados, análisis de cobertura y generación de datasets finales.	Datasets limpios, tablas de calidad, figuras descriptivas y documento de Ingeniería del Dato.
5. Análisis del dato	Mayo, semanas 3-4 y junio, semana 1	Aplicación de pysentimiento tweet a tweet, revisión cualitativa reducida, agregación mensual y construcción del ITIm.	Tweets clasificados, ITIm mensual, figuras y documento de Análisis del Dato.
6. Comparación ITIm-ICC	Junio, semana 1	Integración del ITIm con el ICC, análisis en niveles y diferencias, correlaciones Pearson y Spearman y desfases de +/- 1 mes.	Dataset mensual integrado, tabla de correlaciones y gráficos comparativos.
7. Análisis de negocio	Junio, semana 2	Interpretación de resultados desde perspectiva institucional, conclusiones, limitaciones y recomendaciones accionables.	Documento de Análisis de Negocio.
8. Memoria final	Hasta el 18 de junio	Integración de todas las fases, revisión de coherencia, referencias, figuras, anexos y redacción final.	Memoria final del TFG entregada el 18 de junio.
9. Defensa	Segunda quincena de junio y primera semana de julio	Preparación de presentación, selección de gráficos clave y ensayo de respuestas a preguntas críticas.	Presentación final y guion de defensa.

Tabla 1 Cronograma del proyecto.
Fuente: elaboración propia

1.7. Estado del arte

1.7.1 Introducción

El estado del arte se organiza en torno a cinco líneas de investigación: el ICC como indicador económico, las fuentes digitales para medir sentimiento económico, la comunicación institucional en redes sociales, el análisis de sentimiento aplicado a textos breves y los modelos de PLN en español. Esta revisión permite situar el trabajo dentro de la literatura existente y delimitar con precisión su aportación.

La literatura revisada muestra que existen trabajos sobre confianza del consumidor, análisis de sentimiento económico y comunicación institucional en redes sociales. Sin embargo, es menos frecuente encontrar estudios que comparen de forma mensual un indicador oficial como el ICC con el tono del discurso institucional económico-comercial publicado en X/Twitter. Este anteproyecto parte de esa conexión y propone analizarla desde una perspectiva exploratoria, sin asumir causalidad entre ambas series.

1.7.2 El Índice de Confianza del Consumidor como indicador económico

El ICC es un indicador oficial que aproxima la percepción de los hogares sobre la situación económica actual y sus expectativas. Su interés económico reside en que la confianza de los consumidores se relaciona con decisiones de gasto, ahorro y endeudamiento. Ludvigson (2004) muestra que los indicadores de confianza pueden aportar información sobre el comportamiento del consumo, aunque su capacidad explicativa no debe interpretarse de forma mecánica.

En España, el CIS publica el ICC con periodicidad mensual. Esa periodicidad lo convierte en una variable adecuada para el análisis temporal del presente trabajo. También impone una condición metodológica: cualquier comparación con tweets debe agregarse al mismo nivel temporal. Por eso el sentimiento se estima a nivel de tweet, pero se compara con el ICC a través de un índice mensual.

El ICC no mide reacción a tweets ni percepción de la comunicación institucional. Mide confianza económica ciudadana. Esta precisión evita una confusión frecuente: comparar el ICC con el ITIm no implica equiparar opinión ciudadana y discurso institucional. Se comparan dos series distintas que pueden estar sometidas a un contexto económico común.

1.7.3 Nuevas fuentes digitales para el análisis del sentimiento económico

La incorporación de textos digitales al análisis económico responde a una limitación de los indicadores tradicionales: su periodicidad y su retraso de publicación. Las encuestas oficiales son comparables y metodológicamente sólidas, pero no siempre captan con rapidez los cambios del discurso público o mediático.

Aguilar et al. (2020) construyen un indicador de sentimiento económico basado en noticias y muestran que las fuentes textuales pueden complementar indicadores tradicionales. Bollen, Mao y Zeng (2011) analizaron estados de ánimo agregados en Twitter y su relación con variables financieras. Estos trabajos no son equivalentes al

presente TFG, porque se centran en noticias o sentimiento ciudadano, pero muestran que el texto digital puede convertirse en una señal temporal analizable.

La diferencia de este trabajo es que no utiliza tweets ciudadanos. Utiliza tweets institucionales. X/Twitter funciona aquí como registro observable del discurso emitido por una institución pública, no como encuesta de opinión.

1.7.4 Comunicación institucional y discurso económico en redes sociales

La comunicación institucional en redes sociales tiene una naturaleza propia. No refleja una conversación espontánea, sino mensajes emitidos por una organización con objetivos públicos, calendario comunicativo y lenguaje formal. En contextos de crisis, esta comunicación puede cumplir funciones informativas, preventivas y explicativas.

Pulido-Polo et al. (2022) estudian Twitter como herramienta de comunicación institucional en el contexto postpandémico. Rivas-de-Roca, García-Gordillo y Rojas-Torrijos (2021) analizan estrategias comunicativas de gobiernos europeos durante la segunda ola de COVID-19. Al-Omoush, Garrido y Cañero (2023) conectan el uso gubernamental de redes sociales con confianza y actitudes ciudadanas en contextos de crisis. Estas líneas justifican que las redes sociales institucionales se estudien como canal relevante de comunicación pública.

En el ámbito económico-comercial, el tono institucional puede variar en función del contexto: medidas de apoyo, campañas de consumo, mensajes sobre recuperación, alertas, datos macroeconómicos o iniciativas de comercio exterior. El interés del TFG está en observar si esos cambios de tono se alinean o divergen respecto al ICC.

1.7.5 Análisis de sentimiento aplicado a textos breves

El análisis de sentimiento es una tarea de PLN orientada a clasificar la polaridad de un texto. Pang y Lee (2008) sistematizan el campo y muestran la evolución desde enfoques léxicos hasta métodos estadísticos. En textos breves, como tweets, la tarea presenta dificultades específicas: poco contexto, hashtags, menciones, elipsis, lenguaje comprimido y ambigüedad.

Los tweets institucionales añaden otra dificultad: tienden a ser formales, informativos y de baja carga emocional explícita. La neutralidad del discurso institucional puede ser un rasgo del registro administrativo, no necesariamente ausencia de estrategia.

Un mensaje preventivo sobre inflación o ayudas puede estar redactado de forma neutral, aunque responda a un contexto económico crítico.

Por esta razón, el análisis de sentimiento automático debe interpretarse con cautela. La clasificación positiva, negativa o neutra no agota el significado del discurso. Sirve como señal agregada, especialmente cuando se analiza su evolución mensual y se complementa con revisión cualitativa.

1.7.6 Modelos de análisis de sentimiento en español

La aplicación del análisis de sentimiento al español requiere modelos adaptados al idioma y, si es posible, al dominio de redes sociales. El desarrollo de estos modelos se apoya en la arquitectura transformer, que permitió representar secuencias textuales mediante mecanismos de atención y supuso un cambio importante en el procesamiento del lenguaje natural (Vaswani et al., 2017). BERT introdujo un enfoque contextual que representa cada palabra según el entorno en que aparece (Devlin et al., 2019). A partir de ese marco se han desarrollado modelos específicos para distintas lenguas y dominios.

BETO es una adaptación de BERT entrenada para español (Cañete et al., 2020). MarIA ofrece modelos de lenguaje en español entrenados sobre corpus de gran escala (Gutiérrez-Fandiño et al., 2022). RoBERTuito está entrenado sobre textos de redes sociales en español y resulta especialmente pertinente cuando el corpus procede de X/Twitter (Pérez et al., 2022).

El trabajo utiliza pysentimiento como herramienta principal porque proporciona modelos preentrenados para análisis de sentimiento y tareas de Social NLP en español (Pérez et al., 2021). Esta elección es coherente con el corpus, evita depender de un etiquetado manual masivo y permite reproducir la clasificación sobre el conjunto completo de tweets. La revisión cualitativa se plantea como control de plausibilidad, no como entrenamiento supervisado propio.

1.7.7 Limitaciones en la literatura

La literatura revisada deja varias limitaciones que afectan al presente trabajo. Primero, muchos estudios de sentimiento económico utilizan noticias o publicaciones ciudadanas, pero no discurso institucional. Segundo, los trabajos sobre comunicación institucional suelen centrarse en estrategias, temas o crisis, pero no siempre construyen una serie cuantitativa de tono comparable con un indicador económico oficial.

Tercero, los modelos de sentimiento pueden fallar en lenguaje institucional. La formalidad reduce la carga emocional explícita y aumenta la probabilidad de clasificación neutra. Cuarto, la comparación entre una serie textual y un indicador económico oficial no permite establecer causalidad sin un diseño causal específico. Este TFG se sitúa deliberadamente en el terreno exploratorio y correlacional.

Quinto, el uso de scraping web introduce limitaciones de cobertura. El corpus procede de publicaciones públicas disponibles y puede verse afectado por restricciones técnicas de acceso a X/Twitter y por la disponibilidad de instancias alternativas. Por ello, la ingeniería del dato debe documentar el origen, el filtrado, las ausencias y la cobertura mensual.

1.7.8 Vacío identificado

El vacío identificado es específico: hay literatura sobre confianza del consumidor, análisis de sentimiento, redes sociales y comunicación institucional, pero son escasos los trabajos que comparan un indicador oficial como el ICC con el tono del discurso institucional económico-comercial en X/Twitter.

Este TFG contribuye a ese vacío mediante una metodología reproducible: limpia un corpus institucional, aplica análisis de sentimiento tweet a tweet, construye un ITIm mensual y lo compara con el ICC mediante análisis gráfico, correlaciones, desfases y diferencias intermensuales. El resultado no pretende demostrar una relación causal. Pretende hacer observable una posible relación temporal entre dos señales distintas del mismo contexto económico.

2. OBJETIVO GENERAL Y OBJETIVOS ESPECÍFICOS

2.1. Objetivo general

Analizar la relación temporal entre la evolución mensual del Índice de Confianza del Consumidor y el tono del discurso institucional publicado en X/Twitter por cuentas del ámbito económico-comercial durante 2020-2025, con el fin de identificar patrones de alineación, desfase o divergencia entre ambas series.

2.2. Objetivos específicos

1. Caracterizar la evolución mensual del ICC durante 2020-2025 y documentar los meses sin dato disponible.
2. Construir un corpus limpio de tweets institucionales del ámbito económico-comercial, con corpus principal en @_minecogob y uso complementario de @SE_Comercio.
3. Aplicar análisis de sentimiento tweet a tweet mediante un modelo preentrenado en español y redes sociales, y agregar los resultados en un índice mensual de tono institucional.
4. Incorporar un modelo no supervisado de agrupación temática de tweets mediante técnicas de text mining, con el fin de identificar bloques de contenido recurrentes dentro del discurso institucional.
5. Analizar la distribución del sentimiento institucional y su evolución temporal durante el periodo de estudio.
6. Comparar el ITIm con el ICC mediante análisis gráfico, correlaciones, desfases temporales y diferencias intermensuales.
7. Interpretar los resultados desde una perspectiva comunicativa e institucional, evitando inferencias causales no demostradas.

3. METODOLOGÍA

La metodología adopta un enfoque cuantitativo, longitudinal y comparativo. El trabajo transforma dos fuentes heterogéneas en series mensuales comparables: una serie oficial de confianza ciudadana y una serie textual agregada de tono institucional. La comparación se realiza a nivel mensual porque esa es la periodicidad del ICC.

3.1. Fuentes de datos

El proyecto utiliza dos fuentes principales: la serie histórica del ICC y un corpus de tweets institucionales. La tabla siguiente resume su función dentro del trabajo.

Fuente	Tipo de dato	Periodo	Uso del TFG
Índice de Confianza del Consumidor	Serie mensual oficial del CIS	2004-2026; análisis principal 2020-2025	Variable de referencia para representar la percepción económica ciudadana.
Tweets de @_minecogob	Texto institucional y métricas públicas	Corpus principal 2020-2025	Base principal para estimar el tono del discurso

			institucional y construir el ITIm
Tweets de @SE_Comercio	Texto institucional complementario	2020-2025	Fuente complementaria para contextualizar el ámbito comercial.

Tabla 2 Fuentes de datos utilizadas
Fuente: elaboración propia.

3.2. Procedimiento metodológico

El proyecto seguirá una metodología basada en el análisis de dos fuentes históricas: la serie mensual del Índice de Confianza del Consumidor y un corpus de tweets institucionales publicados en X/Twitter por cuentas vinculadas al ámbito económico-comercial. En primer lugar, se revisará la estructura de ambas fuentes y se seleccionará el periodo común de análisis, comprendido entre enero de 2020 y diciembre de 2025.

Después, se llevará a cabo la preparación de los datos. En el caso del ICC, se normalizarán las fechas, se comprobará la disponibilidad mensual del indicador y se documentarán los meses sin dato oficial. En el caso de los tweets, se aplicarán procesos de filtrado temporal, eliminación de duplicados, limpieza del texto y selección del corpus principal, formado por las publicaciones de la cuenta @_minecogob.

Una vez construido el corpus limpio, se aplicará un modelo preentrenado de análisis de sentimiento en español y redes sociales para clasificar cada tweet como positivo, negativo o neutro. El objetivo de esta fase no será predecir el ICC, sino transformar el discurso institucional en una señal analítica comparable en el tiempo.

De forma complementaria, se incorporará un modelo no supervisado de agrupación temática de tweets. Para ello, el texto limpio se representará mediante TF-IDF y posteriormente se aplicará un algoritmo de clustering, como KMeans, con el objetivo de agrupar publicaciones con vocabulario y contenido similares. Este modelo no utiliza etiquetas manuales ni clasifica la polaridad del discurso. Su función es complementar el análisis de sentimiento, permitiendo observar qué tipos de contenidos aparecen de forma recurrente en el corpus institucional.

Posteriormente, las etiquetas de sentimiento se agregarán por mes para construir el Índice de Tono Institucional mensual, ITIm. El ITIm se calculará como la diferencia entre tweets positivos y negativos dividida entre el total mensual de tweets, de forma que valores más altos reflejen un tono institucional más positivo y valores más bajos un tono más negativo. Este índice permitirá observar la evolución mensual del tono institucional y

compararla con la evolución del ICC, manteniendo una misma unidad temporal entre ambas fuentes.

La adecuación de ambos modelos se valorará de acuerdo con su naturaleza. En el caso del modelo preentrenado de sentimiento, se analizarán la cobertura de clasificación, la distribución de clases, la confianza media y una revisión cualitativa reducida. En el caso del clustering no supervisado, se utilizarán métricas como silhouette score, inercia, distribución de tamaños de cluster, términos principales y ejemplos representativos. Estas medidas permiten valorar el funcionamiento de los modelos sin convertir el trabajo en una predicción del ICC.

Finalmente, se analizará la relación entre el ITIm y el ICC mediante visualizaciones, correlaciones, desfases temporales y variaciones intermensuales. Los resultados se interpretarán desde una perspectiva comunicativa e institucional, evitando afirmar causalidad y valorando si ambas series muestran patrones de alineación, desfase o divergencia durante el periodo analizado.

4. REFERENCIAS

- Aguilar, P., Ghirelli, C., Pacce, M., & Urtasun, A. (2020). *Can news help measure economic sentiment? An application in COVID-19 times* (Documentos de Trabajo No. 2027). Banco de España. <https://www.bde.es/f/webbde/SES/Secciones/Publicaciones/PublicacionesSeriadas/DocumentosTrabajo/20/Files/dt2027e.pdf>
- Al-Omoush, K. S., Garrido, R., & Cañero, J. (2023). The impact of government use of social media and social media contradictions on trust in government and citizens' attitudes in times of crisis. *Journal of Business Research*, 159, Article 113748. <https://doi.org/10.1016/j.jbusres.2023.113748>
- Bollen, J., Mao, H., & Zeng, X. (2011). Twitter mood predicts the stock market. *Journal of Computational Science*, 2(1), 1–8. <https://doi.org/10.1016/j.jocs.2010.12.007>
- Cañete, J., Chaperon, G., Fuentes, R., Ho, J.-H., Kang, H., & Pérez, J. (2020). *Spanish pre-trained BERT model and evaluation data*. Practical Machine Learning for Developing Countries Workshop at ICLR 2020. <https://users.dcc.uchile.cl/~jperez/papers/pml4dc2020.pdf>
- Centro de Investigaciones Sociológicas. (s. f.). *Metodologías y preguntas fijas de ICC*. Recuperado el 18 de junio de 2026, de <https://www.cis.es/es/estudios/metodologia/metodologias-y-preguntas-fijas-de-icc>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. En *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)* (pp. 4171–4186). Association for Computational Linguistics. <https://doi.org/10.18653/v1/N19-1423>

- Gutiérrez-Fandiño, A., Armengol-Estapé, J., Pàmies, M., Llop-Palao, J., Silveira-Ocampo, J., Carrino, C. P., Gonzalez-Agirre, A., Armentano-Oller, C., Rodriguez-Penagos, C., & Villegas, M. (2022). MarIA: Spanish language models. *Procesamiento del Lenguaje Natural*, 68, 39–60. <https://doi.org/10.26342/2022-68-3>
- Ludvigson, S. C. (2004). Consumer confidence and consumer spending. *Journal of Economic Perspectives*, 18(2), 29–50. <https://doi.org/10.1257/0895330041371222>
- Pang, B., & Lee, L. (2008). Opinion mining and sentiment analysis. *Foundations and Trends in Information Retrieval*, 2(1–2), 1–135. <https://doi.org/10.1561/15000000011>
- Pérez, J. M., Rajngewerc, M., Giudici, J. C., Furman, D. A., Luque, F. M., Alonso Alemany, L., & Martínez, M. V. (2021). *pysentimiento: A Python toolkit for opinion mining and social NLP tasks*. arXiv. <https://arxiv.org/abs/2106.09462>
- Pérez, J. M., Furman, D. A., Alonso Alemany, L., & Luque, F. M. (2022). RoBERTuito: A pre-trained language model for social media text in Spanish. En *Proceedings of the Thirteenth Language Resources and Evaluation Conference* (pp. 7235–7243). European Language Resources Association. <https://aclanthology.org/2022.lrec-1.785/>
- Pulido-Polo, M., Jiménez-Marín, G., Pérez-Curiel, C., & Vázquez-González, J. (2022). Twitter as an institutional communication tool for the British Royal Family and the Spanish Royal Family in the post-pandemic context. *Revista de Comunicación*, 21(2), 225–243. <https://doi.org/10.26441/RC21.2-2022-A11>
- Rivas-de-Roca, R., García-Gordillo, M., & Rojas-Torrijos, J. L. (2021). Estrategias comunicativas en Twitter y portales institucionales durante la segunda ola de Covid-19: análisis de los gobiernos de Alemania, España, Portugal y Reino Unido. *Revista Latina de Comunicación Social*, 79, 49–72. <https://doi.org/10.4185/RLCS-2021-1517>
- Kemp, S. (2024, 21 de febrero). *Digital 2024: Spain*. DataReportal. <https://datareportal.com/reports/digital-2024-spain>