

**COMPARATIVA DEL ÍNDICE SENTIMIENTO DEL CONSUMIDOR
CON EL ANÁLISIS DE SENTIMIENTO DEL DISCURSO CON TWEETS
DE MINISTERIO DE COMERCIO EN DISTINTOS MOMENTOS**

COMPARISON OF THE CONSUMER SENTIMENT INDEX WITH
SENTIMENT ANALYSIS OF TWEETS FROM THE MINISTRY OF TRADE AT
DIFFERENT POINTS IN TIME

Alumno: Nadia González Guarner

Email: nadia122004@gmail.com

Grado en Business Analytics

Curso académico 2025-2026

ÍNDICE

1.	Introducción	2
2.	Objetivos de la fase de ingeniería del dato	2
3.	Contexto del proyecto y fuentes utilizadas.....	2
4.	Ingeniería del dato	3
4.1	Origen de los datos y descripción de las fuentes	3
4.2	Proceso de extracción de datos	5
4.3	Validación inicial de los datos.....	5
4.4	Proceso de limpieza de datos.....	6
4.5	Detección de valores extremos	9
4.6	Análisis exploratorio y cobertura mensual.....	10
4.7	Agregación mensual de tweets	11
4.8	Integración del dataset mensual tweets-ICC.....	11
4.9	Datasets finales generados.....	12
4.10	Adecuación del dataset para el análisis del dato	12
5.	Limitaciones	13
6.	Conclusiones.....	15

Índice de tablas

Tabla 1 Fuentes de datos utilizadas en el proceso de ingeniería del dato.	3
Tabla 2 Principales transformaciones aplicadas durante la ingeniería del dato.....	9
Tabla 3 Disponibilidad conjunta de tweets e ICC para el periodo 2020-2025	12
Tabla 4 Datasets finales exportados tras el proceso de ingeniería del dato	12

1. INTRODUCCIÓN

El presente documento describe el proceso de ingeniería del dato desarrollado para el Trabajo de Fin de Grado (TFG) titulado: “Comparativa del índice sentimiento del consumidor con el análisis de sentimiento del discurso con tweets de ministerio de comercio en distintos momentos”. Este proceso constituye la fase previa e imprescindible al análisis comparativo, y tiene como finalidad garantizar que los datos utilizados sean de calidad suficiente, estén correctamente estructurados y sean integrables entre sí.

El TFG tiene por objeto analizar la relación, alineación, desfase o divergencia entre dos señales vinculadas al contexto económico español: el Índice de Confianza del Consumidor (ICC), publicado mensualmente por el Centro de Investigaciones Sociológicas (CIS), y el tono del discurso institucional del Ministerio de Economía, Comercio y Empresa, aproximado a partir de las publicaciones realizadas en X/Twitter por la cuenta oficial @_minecogob y, de forma complementaria, por @SE_Comercio.

A efectos metodológicos, el “índice sentimiento del consumidor” se operacionaliza mediante el ICC porque es una serie oficial, mensual y comparable en el tiempo. El “análisis de sentimiento del discurso con tweets de ministerio de comercio” se operacionaliza mediante el análisis de sentimiento de las publicaciones institucionales de las cuentas mencionadas, con corpus principal en @_minecogob y uso complementario de @SE_Comercio.

El periodo de estudio comprende enero de 2020 a diciembre de 2025 (72 meses posibles). Este intervalo se ha seleccionado porque coincide con la actividad regular de la cuenta principal, incluye episodios macroeconómicos de especial relevancia, como la pandemia de COVID-19, la recuperación económica, las presiones inflacionistas y la estabilización posterior, y ofrece cobertura casi completa del ICC (68 observaciones de 72 posibles).

Conviene subrayar que el objetivo del TFG no es predecir el ICC ni demostrar causalidad entre las variables. El análisis es de carácter exploratorio y correlacional: busca identificar si existe asociación, alineación, desfase o divergencia entre el tono del discurso institucional y la evolución mensual del ICC. La presente entrega no adelanta ningún resultado del análisis de sentimiento.

La ingeniería del dato abarca desde la descripción de las fuentes y el proceso de extracción hasta la obtención de un dataset mensual integrado, limpio y listo para la fase de análisis.

2. OBJETIVOS DE LA FASE DE INGENIERÍA DEL DATO

Los objetivos específicos de esta fase son los siguientes:

- Validar la estructura, integridad y calidad de las fuentes de datos.
- Normalizar fechas, campos numéricos y claves temporales en ambas fuentes.
- Filtrar y justificar el periodo de análisis 2020-2025.
- Seleccionar el corpus principal @_minecogob y conservar @SE_Comercio como corpus complementario.
- Limpiar el texto de los tweets manteniendo la trazabilidad con el contenido original.
- Documentar valores nulos, duplicados y valores extremos.
- Agregar el corpus de tweets a nivel mensual.
- Integrar tweets e ICC en un dataset común mediante una clave temporal mensual.
- Documentar decisiones metodológicas, ausencias y limitaciones.
- Generar datasets reproducibles y preparados para la fase de análisis del dato.

3. CONTEXTO DEL PROYECTO Y FUENTES UTILIZADAS

El TFG se enmarca en el análisis de datos aplicado al ámbito económico e institucional. El ICC es un indicador compuesto de percepción ciudadana elaborado mensualmente por el CIS desde 2004. Por su parte, el discurso institucional del Ministerio de Economía, Comercio y Empresa es público y accesible a través de X/Twitter. La comparación de ambas señales permite explorar si el tono del discurso institucional guarda relación temporal con la percepción económica de los ciudadanos.

Las fuentes de datos del TFG son:

- Tweets institucionales: corpus obtenido mediante scraping web de las cuentas @_minecogob y @SE_Comercio en X/Twitter.
- Índice de Confianza del Consumidor (ICC): serie oficial publicada mensualmente por el CIS, descargada en formato CSV desde su portal de datos abiertos.

Fuente	Tipo de dato	Origen	Periodo disponible	Uso en el TFG
Tweets institucionales	Texto y métricas de interacción	Scraping web de X/Twitter mediante Nitter	Febrero 2012 - abril 2026	Base textual inicial para el análisis de sentimiento
@_minecogob	Tweets institucionales	Cuenta oficial del Ministerio de Economía, Comercio y Empresa	2020-2025 para el análisis principal	Corpus principal por volumen y cobertura mensual
@SE_Comercio	Tweets institucionales	Secretaría de Estado de Comercio	2020-2025	Corpus complementario descriptivo
Índice de Confianza del Consumidor (ICC)	Serie temporal mensual	Centro de Investigaciones Sociológicas (CIS)	Septiembre 2004 - enero 2026	Variable oficial de referencia para comparar con el tono institucional

Tabla 1 Fuentes de datos utilizadas en el proceso de ingeniería del dato.
Fuente: elaboración propia

4. INGENIERÍA DEL DATO

4.1 Origen de los datos y descripción de las fuentes

Tweets institucionales: corpus @_minecogob

El corpus de tweets procede de la cuenta oficial @_minecogob en la red social X, perteneciente al Ministerio de Economía, Comercio y Empresa del Gobierno de España. Esta cuenta publica información relativa a política comercial, medidas económicas, datos macroeconómicos y declaraciones institucionales.

Los datos fueron recopilados mediante scraping web a través de instancias públicas de Nitter, utilizando el proxy Tor para gestionar restricciones de acceso. La base de datos

resultante contiene 11.198 registros que abarcan desde febrero de 2012 hasta abril de 2026; para el análisis del TFG se restringe a enero de 2020-diciembre de 2025.

Cada registro incluye los siguientes campos:

- id - identificador único del tweet.
- fecha - fecha y hora de publicación en UTC.
- username - cuenta que lo publica.
- contenido - texto íntegro del tweet.
- hashtags, tipo, url_media - metadatos adicionales.
- comentarios, retweets, likes, views - métricas de interacción.

Además de @minecogob, el corpus contiene publicaciones de la cuenta @SE_Comercio (Secretaría de Estado de Comercio) y otras cuentas vinculadas. Estas presentan un volumen significativamente inferior y una cobertura mensual incompleta durante el periodo de análisis, por lo que se utilizan exclusivamente como corpus complementario de carácter descriptivo.

Índice de Confianza del Consumidor (ICC)

La serie del ICC procede del Centro de Investigaciones Sociológicas (CIS) de España. El ICC es un indicador compuesto que mide la percepción de los ciudadanos sobre la situación económica actual y sus expectativas a corto plazo. Se publica mensualmente con periodicidad regular, aunque habitualmente no hay publicación en el mes de agosto.

El archivo contiene la serie histórica del ICC desde septiembre de 2004 hasta enero de 2026. Tras la validación inicial y la eliminación de filas no válidas, se obtiene la serie estructurada utilizada en el análisis. Para el periodo 2020-2025, el dataset ofrece 68 observaciones de 72 meses posibles, ya que los meses de agosto de 2022, 2023, 2024 y 2025 no tienen dato publicado por el CIS.

La estructura del fichero es la siguiente:

- Año - año de la observación.
- Periodo - nombre del mes en español.

- Confianza del consumidor - valor numérico del índice, con decimales separados por coma. Separador de campo: punto y coma (;).

4.2 Proceso de extracción de datos

Extracción de tweets

La extracción del corpus de tweets se realizó mediante un scraper automatizado implementado en Python, con Selenium y Google Chrome como navegador controlado. Las peticiones se enrutaron a través del proxy Tor (puerto SOCKS 9150) para gestionar restricciones de acceso.

El scraper accedió a instancias públicas de Nitter (nitter.poast.org, nitter.privacydev.net, nitter.1d4.us y nitter.net) de forma secuencial ante posibles fallos o limitaciones de tasa. Para cada instancia, se verificaba la presencia de elementos del tipo timeline-item, considerando el resultado válido únicamente cuando se detectó contenido.

El proceso fue iterativo: para cada página de resultados se extrajo el contenido textual, las métricas de interacción y los metadatos de cada tweet, almacenándolos en un archivo CSV en modo de escritura incremental (modo append). En caso de error, el scraper registraba la incidencia y continuaba con la siguiente instancia o renovaba la dirección IP de Tor.

El scraping permitió obtener un corpus amplio de publicaciones públicas disponibles, aunque no puede garantizarse exhaustividad absoluta por las limitaciones técnicas de acceso a X/Twitter y por la disponibilidad variable de instancias de Nitter. El proceso se documentó en el notebook Código_análisis.ipynb.

Descarga del ICC

La serie del ICC se descargó directamente desde el portal de datos abiertos del CIS en formato CSV, con separador de punto y coma, en su versión más actualizada disponible en el momento de la extracción (hasta enero de 2026). No requirió ningún proceso de scraping, al tratarse de un fichero de descarga directa en formato estructurado.

4.3 Validación inicial de los datos

Dimensiones y estructura del corpus de tweets

Tras la carga del archivo, el corpus completo presenta 11.198 filas y 11 columnas. La validación inicial confirmó la presencia de todas las columnas requeridas (id, fecha, username, contenido, comentarios, retweets, likes, views, hashtags, tipo, url_media). Algunos campos como hashtags y url_media registran un elevado porcentaje de valores ausentes, lo que es coherente con la naturaleza del contenido institucional.

El campo id, utilizado como identificador único, no presentó valores nulos en la inspección inicial. Sin embargo, se detectaron duplicados que fueron tratados en la fase de limpieza. El campo fecha se encontraba en formato textual con la estructura “Mes DD, YYYY · HH:MM AM/PM UTC” (ejemplo: “Apr 23, 2026 · 4:06 PM UTC”), lo que requirió un proceso de normalización previo a la conversión a tipo datetime.

Estructura del ICC

El dataset del ICC presentó 3 columnas (Año, Periodo y Confianza del consumidor). No se detectaron valores nulos en ninguna de las tres columnas. El tipo de dato de la columna Confianza del consumidor era cadena de texto por el uso de la coma como separador decimal, lo que requirió una transformación de tipo en la fase de normalización. Se eliminaron las filas en las que el campo Año no contenía un valor numérico válido antes de proceder a la conversión de tipos.

4.4 Proceso de limpieza de datos

Normalización de fechas de tweets

Las fechas del corpus de tweets se encontraban en un formato textual que incluía el separador “.” y la zona horaria “UTC” al final de la cadena. El proceso de conversión a tipo datetime fue: (1) sustitución del separador “.” por un espacio en blanco; (2) eliminación del literal “ UTC”; (3) conversión al tipo datetime de pandas con el formato “%b %d, %Y %I:%M %p”. Los registros no parseables (errors='coerce') quedaron con valor NaT y fueron inspeccionados.

Una vez convertido el campo, se creó la columna mes, que almacena el primer día del mes correspondiente a cada tweet. Esta columna es la clave de unión temporal con la serie del ICC.

Normalización de fechas del ICC

Las fechas del ICC se construyeron a partir de las columnas Año y Periodo. El campo Periodo contenía el nombre del mes en español, por lo que se aplicó un diccionario de mapeo para convertirlo al número de mes correspondiente. A continuación, se generó la columna fecha_mes como combinación de año, número de mes y día 1 mediante pd.to_datetime(). El campo Confianza del consumidor se convirtió de string a float sustituyendo la coma por el punto como separador decimal.

Filtrado temporal 2020-2025

De los 11.198 tweets del corpus completo, se filtraron aquellos comprendidos entre el 1 de enero de 2020 y el 31 de diciembre de 2025. Este filtro redujo el corpus al subconjunto relevante para el TFG, descartando publicaciones anteriores a 2020 y posteriores a 2025. La proporción de tweets conservados y su distribución por año quedaron documentadas como parte de la validación.

Para el ICC, el filtro temporal redujo la serie a las 68 observaciones comprendidas en el intervalo 2020-2025.

Selección del corpus principal

Del corpus filtrado temporalmente, se seleccionaron exclusivamente las publicaciones de @_minecogob como corpus principal del análisis. La justificación es la siguiente:

- Relevancia institucional: es la cuenta oficial del Ministerio de Economía, Comercio y Empresa, con competencia directa sobre política comercial y económica.
- Cobertura temporal: es la única cuenta del corpus que presenta actividad mensual continua y suficiente durante todo el periodo 2020-2025.
- Volumen: concentra el mayor número de publicaciones del ámbito analizado en el periodo de estudio.
- Coherencia temática: el contenido de sus publicaciones está vinculado a la gestión económica y comercial del Gobierno, lo que lo hace pertinente para la comparación con un indicador de confianza económica, sin equiparar ambas señales.

La cuenta @SE_Comercio se conservó como corpus complementario para un análisis descriptivo de apoyo, dado su volumen reducido y su cobertura mensual incompleta. Su inclusión en el análisis principal comprometería la comparabilidad mensual con el ICC.

Tratamiento de duplicados

Se identificaron y eliminaron los registros duplicados utilizando el campo id como clave de deduplicación, conservando únicamente la primera aparición de cada tweet. Adicionalmente, se inspeccionaron los duplicados por combinación de contenido y fecha para detectar posibles retweets automáticos o publicaciones repetidas. Los registros eliminados en esta fase se documentaron cuantitativamente.

Limpieza textual

El texto de los tweets se sometió a una limpieza estándar orientada a eliminar elementos no informativos para el análisis de sentimiento. El proceso aplicado fue:

- Eliminación de URLs (patrones http/https y www).
- Eliminación de menciones a otras cuentas (@usuario).
- Eliminación del símbolo # conservando la palabra del hashtag, dado que en el discurso institucional los hashtags suelen ser parte del contenido semántico.
- Eliminación de saltos de línea y retornos de carro.
- Colapso de espacios múltiples en un único espacio.
- Conversión a minúsculas.

El texto limpio se almacenó en una nueva columna texto_limpio, conservando el contenido original en la columna contenido para trazabilidad. Se registraron los casos en los que el texto quedó vacío tras la limpieza, ya que dichos tweets no aportarían información al análisis de sentimiento.

Normalización de métricas numéricas de interacción

Las columnas de métricas de interacción (comentarios, retweets, likes y views) se encontraban almacenadas como cadenas de texto en el CSV original, con puntos o comas

como separadores de miles en algunos casos. Se aplicó una normalización que eliminó los separadores de miles, trató las cadenas vacías como cero y convirtió todos los valores al tipo entero. Los valores no numéricos se imputaron a cero tras la conversión.

Elemento tratado	Transformación aplicada	Justificación
Fechas de tweets	Conversión de texto a datetime y creación de columna mes	Permite agregar tweets por mes y unirlos con el ICC
Fechas del ICC	Conversión de año y mes textual a fecha mensual	Estandariza la serie temporal para la integración
Valor del ICC	Conversión de texto con coma decimal a valor numérico	Permite análisis estadístico posterior
Periodo temporal	Filtrado enero 2020 - diciembre 2025	Delimita el periodo de análisis del TFG
Corpus principal	Selección de @_minecogob y conservación de @SE_Comercio como complementario	Garantiza cobertura mensual y coherencia temática
Duplicados	Eliminación por id, conservando la primera aparición	Evita contar dos veces una misma publicación
Texto de tweets	Eliminación de URLs, menciones, saltos de línea, espacios múltiples y normalización a minúsculas	Prepara el corpus para el análisis de sentimiento
Métricas de interacción	Conversión de texto a enteros y tratamiento de valores no numéricos	Permite análisis descriptivo y detección de outliers
Meses sin ICC	Conservación como NaN, sin imputación	Evita introducir valores artificiales en un indicador oficial

Tabla 2 Principales transformaciones aplicadas durante la ingeniería del dato. Fuente: elaboración propia

4.5 Detección de valores extremos

Se realizó una revisión específica de valores extremos en las métricas de interacción: comentarios, retweets, likes y views. Para ello se emplearon estadísticos descriptivos (media, mediana, desviación típica, mínimo y máximo) y el criterio de rango intercuartílico (IQR), identificando como potenciales outliers los valores que superan el límite $1,5 \times \text{IQR}$ por encima del tercer cuartil.

Los valores extremos detectados no se eliminaron automáticamente, ya que pueden corresponder a publicaciones institucionales con alta repercusión pública vinculada a eventos económicos relevantes, como anuncios de política económica o datos macroeconómicos de especial interés. Su tratamiento queda documentado para evitar que influyan de forma no controlada en análisis posteriores. Las métricas de interacción se consideran variables de contexto, no variables principales del análisis comparativo.

Las visualizaciones generadas en el notebook para esta sección incluyen diagramas de caja (boxplots) y distribución de frecuencias para cada métrica, que permiten identificar visualmente la posición y magnitud de los valores extremos en cada variable de interacción.

4.6 Análisis exploratorio y cobertura mensual

Se realizó un análisis exploratorio descriptivo completo sobre ambas fuentes de datos. A continuación se detallan los principales resultados.

Corpus de tweets @_minecogob

Las visualizaciones generadas en el notebook incluyen:

Distribución anual de tweets: gráfico de barras con el número de publicaciones por año. El volumen de publicaciones creció a lo largo del periodo, con un incremento visible a partir de 2022-2023, lo que sugiere una mayor actividad comunicativa institucional en esos años.

- Distribución mensual de tweets: gráfico de barras con la media o el total de publicaciones por mes del año (enero-diciembre), que permite identificar patrones estacionales en la actividad institucional.
- Cobertura mensual del corpus principal: mapa de calor o gráfico de línea con el número de tweets por mes para el periodo 2020-2025, que muestra que la cobertura es continua en todos los meses del intervalo analizado.
- Análisis de nulos y duplicados: tabla con el porcentaje de nulos por columna y el número de duplicados detectados y eliminados.
- Outliers en métricas de interacción: boxplots de comentarios, retweets, likes y views, con identificación de valores atípicos.

Índice de Confianza del Consumidor (ICC)

Las visualizaciones generadas en el notebook incluyen:

- Evolución del ICC 2020-2025: gráfico de línea temporal que muestra la trayectoria del indicador, con los meses de agosto marcados explícitamente como ausentes.

- Estadísticos descriptivos del ICC: media, mediana, desviación típica, mínimo y máximo para el periodo de análisis.
- Meses sin dato de ICC: identificación explícita de los cuatro meses de agosto (2022, 2023, 2024 y 2025) sin observación publicada.

Disponibilidad conjunta tweets-ICC

Se analizó la disponibilidad conjunta de ambas fuentes para cada uno de los 72 meses posibles del periodo 2020-2025, generando una visualización de cobertura simultánea. El resultado confirma que el dataset integrado dispone de 68 meses con ambas fuentes disponibles, base suficiente para el análisis comparativo posterior.

4.7 Agregación mensual de tweets

Dado que el ICC es un indicador de frecuencia mensual, la unidad de análisis del TFG es el mes. El corpus de tweets se agregó a nivel mensual calculando las siguientes métricas para cada mes:

- `n_tweets`: número total de publicaciones del mes.
- `comentarios_sum`, `retweets_sum`, `likes_sum`, `views_sum`: suma de las respectivas métricas de interacción durante el mes.

El dataset resultante de la agregación se reindexó sobre los 72 meses posibles para garantizar la representación explícita de todos los periodos, asignando valor 0 a las métricas de los meses sin tweets. Este tratamiento permite distinguir entre la ausencia de actividad (0 tweets) y la ausencia de dato por falta de información.

El análisis de sentimiento se realizará a nivel de tweet a partir del archivo `tweets_limpios_2020_2025_minecogob.csv`. La agregación mensual se aplicará después sobre las etiquetas de sentimiento obtenidas para construir el índice de tono institucional mensual, no sobre un texto mensual concatenado. Este enfoque conserva la granularidad de cada publicación y mantiene la comparación en la escala mensual del ICC.

4.8 Integración del dataset mensual tweets-ICC

El dataset mensual de tweets (72 observaciones) se unió con la serie mensual del ICC mediante una operación de tipo `left join` sobre la columna `mes` (`fecha_mes` en el ICC),

utilizando el mes como clave común. El resultado es un dataset integrado de 72 filas que contiene, para cada mes, el número de tweets, las métricas de interacción agregadas y el valor del ICC (o NaN si el mes no tiene dato disponible).

Se añadieron dos columnas indicadoras de disponibilidad: `icc_disponible` (True si el mes tiene dato de ICC) y `tweets_disponibles` (True si el mes tiene al menos un tweet). La distribución resultante de la disponibilidad conjunta es la siguiente:

Situación	Número de meses
Tweets e ICC disponibles	68
Solo ICC disponible (sin tweets)	0
Solo tweets disponibles (sin ICC)	4 (agostos sin dato ICC)
Sin ninguna fuente disponible	0

Tabla 3 Disponibilidad conjunta de tweets e ICC para el periodo 2020-2025. Fuente: elaboración propia

El análisis comparativo del TFG se realizará sobre los 68 meses en los que ambas fuentes estén disponibles, con el fin de garantizar la comparabilidad directa entre las dos series. Los cuatro meses de agosto (2022, 2023, 2024 y 2025) sin dato del ICC quedan excluidos del análisis comparativo principal, sin aplicar imputación.

4.9 Datasets finales generados

Como resultado del proceso de ingeniería del dato, se exportaron cuatro archivos en formato CSV:

Archivo	Contenido	Unidad de análisis
<code>tweets_limpios_2020_2025_minecogob.csv</code>	Corpus principal limpio (tweet a tweet)	Tweet
<code>tweets_comercio_complementario_2020_2025.csv</code>	Corpus complementario @SE Comercio	Tweet
<code>icc_2020_2025_limpio.csv</code>	Serie ICC 2020-2025 con meses documentados	Mes
<code>dataset_mensual_tweets_icc.csv</code>	Dataset integrado mensual tweets + ICC	Mes

Tabla 4 Datasets finales exportados tras el proceso de ingeniería del dato. Fuente: elaboración propia

El archivo `dataset_mensual_tweets_icc.csv` es el dataset principal para el análisis comparativo. Contiene una fila por mes (72 filas), con las columnas de volumen de tweets, métricas de interacción agregadas, valor del ICC e indicadores de disponibilidad.

4.10 Adecuación del dataset para el análisis del dato

El dataset final generado está diseñado para permitir el desarrollo completo de la fase de análisis del dato. En concreto:

- Análisis de sentimiento a nivel de tweet: el archivo `tweets_limpios_2020_2025_minecogob.csv` permite aplicar un modelo preentrenado de análisis de sentimiento para español y redes sociales, manteniendo la unidad de observación original de cada publicación.
- Construcción del índice de tono institucional mensual: las etiquetas de sentimiento obtenidas a nivel de tweet se agregarán mensualmente para construir un índice de tono institucional comparable con el ICC.
- Análisis comparativo con el ICC: el dataset integrado permite cruzar el índice de tono institucional con el ICC mes a mes, analizando correlaciones, desfases y divergencias en el periodo 2020-2025.
- Trazabilidad: se conserva la cadena completa entre el tweet original, el texto limpio, el mes de publicación y el valor del ICC, lo que garantiza la reproducibilidad del análisis.
- Adecuación metodológica: el análisis posterior es de carácter exploratorio y correlacional. No se establece ni se busca causalidad entre las series.

5. LIMITACIONES

Limitaciones del scraping y disponibilidad de Nitter

El proceso de extracción dependió de la disponibilidad de instancias públicas de Nitter, sujetas a limitaciones de tasa, bloqueos o inconsistencias de cobertura. El scraping permitió obtener un corpus amplio de publicaciones públicas disponibles, aunque no puede garantizarse exhaustividad absoluta debido a las limitaciones técnicas de acceso a X/Twitter y a la disponibilidad variable de las instancias utilizadas. Los controles de calidad no revelaron lagunas temporales significativas en el periodo principal 2020-2025.

Limitaciones de acceso a la API de X/Twitter

El acceso a la API oficial de X/Twitter está actualmente sujeto a restricciones comerciales y económicas que lo hacen inviable para proyectos académicos sin financiación específica. Por ello, la extracción se realizó mediante scraping de instancias Nitter, que no garantiza las mismas características de completitud y fiabilidad que la API oficial.

Ausencia de ICC en los meses de agosto

Los cuatro meses de agosto del periodo (2022, 2023, 2024 y 2025) no disponen de observación del ICC por decisión del CIS. Estos meses quedan excluidos del análisis comparativo principal. No se aplica imputación para preservar la integridad del indicador, que es una medición directa de la percepción ciudadana en un momento concreto, no susceptible de ser aproximado sin introducir sesgos.

Menor cobertura del corpus complementario @SE_Comercio

La cuenta @SE_Comercio presenta cobertura mensual irregular y un volumen de tweets insuficiente para constituir un corpus de análisis independiente en la mayoría de los meses. Su uso queda limitado a la descripción complementaria del discurso institucional y no se incluye en el análisis comparativo principal.

No comparabilidad de métricas de interacción entre periodos

Las métricas de interacción (likes, retweets, views) no son directamente comparables entre periodos distantes porque el algoritmo de visibilidad de X/Twitter ha cambiado significativamente a lo largo del periodo 2020-2025. Estas métricas se utilizan como indicadores de contexto y no como variables de análisis principal.

Carácter exploratorio y correlacional del análisis

El TFG analiza la relación entre el ICC y el sentimiento del discurso institucional de un único ministerio. El análisis es de carácter exploratorio y correlacional: no establece causalidad entre las variables ni pretende predecir la evolución del ICC. Los resultados no son generalizables al conjunto del discurso político ni a otros indicadores de percepción ciudadana.

Modelo de análisis de sentimiento pendiente de aplicación

Esta fase no aplica todavía el modelo final de análisis de sentimiento. El corpus se deja limpio y estructurado para que, en la fase de análisis del dato, pueda utilizarse un modelo preentrenado adecuado para español y redes sociales sobre cada tweet del corpus principal.

6. CONCLUSIONES

El proceso de ingeniería del dato descrito en este documento ha permitido transformar dos fuentes heterogéneas, un corpus de tweets institucionales en formato textual y una serie temporal de un indicador económico en formato CSV, en datasets limpios, estructurados y listos para la fase de análisis.

Las principales aportaciones de esta fase son:

- Se ha obtenido un corpus limpio tweet a tweet de 4.592 publicaciones institucionales del Ministerio de Economía, Comercio y Empresa para el periodo 2020-2025, estructurado y con trazabilidad completa.
- Se ha construido una serie mensual integrada tweets-ICC con 72 observaciones, de las cuales 68 disponen de ambas fuentes disponibles para el análisis comparativo.
- Se han documentado explícitamente las ausencias (cuatro meses de agosto sin dato de ICC), los duplicados, los valores nulos y los valores extremos en las métricas de interacción.
- Las decisiones metodológicas adoptadas, como la selección del corpus principal, la exclusión de los meses de agosto sin imputación, la granularidad mensual y el tratamiento documentado de outliers, han quedado justificadas.
- El dataset final queda listo para que, en la fase de análisis del dato, se aplique un modelo de sentimiento a nivel de tweet, se construya el índice de tono institucional mensual y se realice el análisis de asociación, alineación, desfase o divergencia con el ICC.

Esta entrega no adelanta resultados del análisis de sentimiento ni establece ninguna conclusión sobre causalidad o asociación entre las variables. El valor de la ingeniería del dato reside en haber generado una base consistente, reproducible y bien documentada, sobre la que la fase de análisis podrá apoyarse con garantías metodológicas.